
Physics-Informed Neural Networks

Cuándo meter la física dentro de la función de pérdida cambia el resultado — y cuándo no

CLASE PRÁCTICA DE PROGRAMACIÓN · ASTROFÍSICA COMPUTACIONAL 2026-I

La pregunta que vamos a responder

Toda presentación de PINNs enseña la fórmula. Casi ninguna dice cuándo conviene usarla. Hoy respondemos eso con un experimento controlado, no con opiniones.

PROBLEMA DIRECTO

Conozco la ecuación y sus parámetros, quiero $u(t)$

Una PINN es una mala idea.

RK4 resuelve esto **1,621× más rápido** y con un error **63,669× menor**. No uses una red neuronal para integrar una EDO que ya sabes integrar.

PROBLEMA INVERSO Y ASIMILACIÓN

Tengo observaciones escasas, ruidosas y con huecos, y quiero el estado continuo y los parámetros físicos

Aquí la física en la pérdida lo cambia todo.

Convierte un ajuste sin sentido en una **medición**. Es el caso real en física solar: cadencia limitada, ruido, variables del plasma que nadie mide directamente.

El límite del "black box"

Una red que solo ve datos no aprende física: aprende correlaciones

- › **Extrapolación mal.** Fuera de la distribución de entrenamiento no hay ninguna garantía; la red hace lo único que sabe, interpolar suavemente.
- › **Sobreajuste al ruido.** Si tiene capacidad suficiente pasa exactamente por cada punto, incluida la parte que es error de medición.
- › **Viola leyes de conservación.** Nada en la pérdida le impide crear masa, momento o energía. Y lo hace.

LO QUE MEDIMOS HOY EN CLASE

Con 14 puntos ruidosos, la red sin física llevó su error de datos a **$3e-13$** : memorizó el ruido exactamente.

Consecuencia física: fabricó un **43 %** de la energía inicial del sistema de la nada.

No es un problema estético. Es un lazo coronal que se amplifica solo, sin fuente.

El paradigma de las PINNs

La red sigue siendo una red; lo que cambia es qué se optimiza

Conocimiento de datos

Aprende de mediciones empíricas y condiciones de contorno o iniciales. Tolera datos ruidosos, escasos o incompletos, que es la situación normal en observaciones solares.

Restricciones físicas

La ecuación diferencial se evalúa sobre la propia red mediante diferenciación automática y su incumplimiento se penaliza. Eso restringe el espacio de soluciones y reduce cuántos datos hacen falta.

La clave: los puntos de colocación no necesitan datos. La física es el dato que falta.

La función de pérdida híbrida

$$L_{\text{total}} = L_{\text{datos}} + \lambda_{\text{fís}} L_{\text{física}} + \lambda_{\text{ci}} L_{\text{ci}}$$

Datos

MSE entre la red y las observaciones.
Solo se evalúa donde hay mediciones.

Física

MSE del residuo de la EDO en puntos de colocación repartidos por todo el dominio, también donde no hay datos.

Iniciales

Ancla la solución: sin esto, la familia de soluciones de la EDO tiene infinitos miembros.

Detalle que decide si funciona: adimensionalizar el residuo dividiéndolo por ω_0^2 . Sin eso los tres términos tienen unidades distintas, λ depende de la escala temporal elegida y aparece la patología de gradientes.

Qué NO es una PINN

Tres malentendidos que hay que desactivar antes de programar

No es un integrador mejorado

Resolver una EDO/EDP conocida con una PINN es más lento y menos preciso que un método clásico. Casi siempre. Sin excepciones cómodas.

No garantiza que se cumpla la física

La pérdida física es una penalización blanda: castiga el incumplimiento, no lo prohíbe. Una PINN mal entrenada viola la ecuación tranquilamente.

No es magia con datos escasos

Si la ecuación impuesta está equivocada, la red devuelve con toda confianza parámetros sin sentido. La física en la pérdida es una hipótesis.

¿Cuándo sí y cuándo no?

Situación	¿PINN?	Por qué
Resolver una EDO/EDP con parámetros conocidos	NO	RK4, diferencias finitas o espectral son órdenes de magnitud mejores
Datos escasos y ruidosos + ecuación conocida	SÍ	La física regulariza e interpola donde no hay observaciones
Estimar parámetros físicos desde observaciones	SÍ	El caso estrella: los parámetros son variables entrenables más
Reconstruir variables no observadas	SÍ	La ecuación acopla lo observado con lo oculto
Geometrías complicadas, mallado difícil	SÍ	Sin malla: solo hacen falta puntos de colocación
Dinámica rígida (stiff) o multiescala	CON CUIDADO	Patologías de gradiente conocidas; suele fallar sin trucos
Se necesita precisión de máquina	NO	Difícil bajar de 10^{-5} – 10^{-6} de error relativo

Caso práctico: oscilación de un lazo coronal

El oscilador amortiguado no es un juguete arbitrario: es el modo kink

$$\ddot{u} + 2\beta \dot{u} + \omega_0^2 u = 0$$

- › $u(t)$ desplazamiento transversal del eje del lazo [Mm]
- › ω_0 tensión magnética como fuerza restauradora → el período P
- › β amortiguamiento, dominado por absorción resonante → el tiempo τ

POR QUÉ IMPORTA

Una fulguración cercana sacude el lazo y este oscila en su modo kink.

Se observa $u(t)$ con TRACE o SDO/AIA, se miden P y τ , y de ahí se infiere el campo magnético coronal y la estructura fina transversal del lazo.

Ninguna de esas dos cosas se mide directamente. Eso es la sismología coronal.

La ley que un modelo debe respetar

No juzgamos por cómo se ve la curva; juzgamos por los observables físicos

$$E = \frac{1}{2} v^2 + \frac{1}{2} \omega_0^2 u^2$$

$$\dot{E} = -2\beta v^2 \leq 0$$

Sustituyendo la ecuación de movimiento en dE/dt , los términos de fuerza restauradora se cancelan y queda solo la disipación. La ley dice dos cosas, y hay que verificar las dos:

Signo

La energía nunca puede aumentar. $\dot{E} > 0$ en cualquier instante es físicamente imposible sin una fuente.

Magnitud

No basta con que baje: debe bajar exactamente a la tasa $2\beta v^2$, que es la potencia disipada.

Energía espuria: la fracción de $E(0)$ que un modelo crea de la nada, $\int \max(\dot{E} + 2\beta v^2, 0) dt / E(0)$. Para la solución verdadera vale cero. Es nuestro detector de violaciones.

El escenario observacional

14 puntos, $\sigma = 0.04$ Mm, y un hueco de cobertura de 8 minutos



La pregunta interesante no es qué hace cada modelo donde hay datos, sino qué inventa donde no los hay.

Paso 1: la arquitectura

Un MLP que actúa como ansatz continuo y diferenciable

```
class MLP(nn.Module):
    def __init__(self, hidden=32, layers=3):
        super().__init__()
        bloques = [nn.Linear(1, hidden), nn.Tanh()]
        for _ in range(layers - 1):
            bloques += [nn.Linear(hidden, hidden), nn.Tanh()]
        bloques += [nn.Linear(hidden, 1)]
        self.net = nn.Sequential(*bloques)

    def forward(self, t):
        # normaliza t -> [-1,1] DENTRO del modelo:
        # autograd deriva respecto al t fisico
        return self.net(2.0*t/T_END - 1.0)
```

POR QUÉ tanh Y NO ReLU

Necesitamos que $\ddot{u}$ exista y sea continua.

ReLU tiene segunda derivada nula en casi todo punto: el residuo de una EDO de segundo orden sería idénticamente cero salvo en un conjunto de medida nula.

La pérdida física no informaría nada.

Paso 2: el residuo con autograd

Derivadas exactas hasta precisión de máquina, sin diferencias finitas

```
def deriv(y, x):  
    # create_graph=True: hace falta para poder derivar OTRA vez  
    return torch.autograd.grad(y, x, torch.ones_like(y), create_graph=True)[0]  
  
def perdidas(model, lam_fis, lam_ci=20.0):  
    l_dat = torch.mean((model(t_data_t) - u_data_t)**2)  
  
    u_c = model(t_col_t)                # puntos de colocacion: SIN datos  
    du = deriv(u_c, t_col_t)           # velocidad  
    d2u = deriv(du, t_col_t)           # aceleracion  
    r = (d2u + 2*beta*du + omega0**2*u_c)/omega0**2    # residuo adimensional  
    l_fis = torch.mean(r**2)  
  
    return l_dat + lam_fis*l_fis + lam_ci*l_ci, l_dat, l_fis, l_ci
```

Paso 3: el entrenamiento

Adam explora, L-BFGS remata — el detalle que casi ningún tutorial menciona

```
# fase 1: Adam con cosine annealing
opt = torch.optim.Adam(model.parameters(), lr=5e-3)
sch = CosineAnnealingLR(opt, epochs_adam, eta_min=1e-4)
for ep in range(epochs_adam):
    opt.zero_grad()
    loss, *_ = perdidas(model, lam_fis)
    loss.backward(); opt.step(); sch.step()

# fase 2: L-BFGS (cuasi-Newton, usa curvatura)
lbfgs = torch.optim.LBFGS(model.parameters(),
                           line_search_fn='strong_wolfe')
def closure():
    lbfgs.zero_grad()
    loss, *_ = perdidas(model, lam_fis)
    loss.backward()
    return loss
lbfgs.step(closure)
```

EL EXPERIMENTO CONTROLADO

Entrenamos DOS modelos con la misma red, el mismo optimizador y los mismos datos.

Lo único que cambia:

$\lambda_{fis} = 0$ → caja negra


$\lambda_{fis} = 30$ → PINN

Cualquier diferencia es atribuible a la pérdida, no al optimizador.

¿Ajusta? Cinemática

Mismo dato, misma red, mismo optimizador — solo cambia la pérdida

Mismo dato, misma red, mismo optimizador: solo cambia la pérdida





A simple vista, en (a) las dos curvas pasan por los puntos. El problema aparece en las derivadas.

¿Respeta la física? Energía


El diagnóstico que separa un ajuste de una reconstrucción física

El veredicto físico: quien respeta la ley de disipacion

(d) Energía: solo puede bajar, y a la tasa correcta (e) Violacion de la ley de disipacion (0 = fisica respetada)



(f) Retrato de fase: la espiral hacia el atractor



(e) es el veredicto: por encima de cero, el modelo está creando energía que ninguna fuente aporta.

Dos formas distintas de fallar

DONDE SÍ HAY DATOS: SOBREAJUSTA EL RUIDO

Para pasar exactamente por cada punto ruidoso, la curva debe curvarse mucho entre punto y punto. Curvatura es aceleración, y esas aceleraciones espurias son energía inyectada. Ajustar el ruido tiene una consecuencia física medible.


DONDE NO HAY DATOS: SE APLANA

En el hueco la caja negra pierde la oscilación por completo: dibuja una joroba suave donde la verdad completa 1.6 ciclos. Sin datos y sin física, una red hace lo único que sabe hacer: interpolar suavemente.

Diagnóstico	Caja negra	PINN	Mejora
RMSE de u [Mm]	0.1504	0.0049	31×
RMSE dentro del hueco [Mm]	0.2603	0.0029	90×
RMSE de v (nunca observada)	0.1154	0.0062	19×
RMS del residuo de la EDO	0.2103	0.0051	41×
Energía espuria / $E(0)$	43.5 %	1.3 %	33×

Cómo la física dobla la curva durante el entrenamiento

Entrenamiento — L-BFGS, iteracion 2000




Ambas redes arrancan idénticas. Encuentran primero los datos y luego reconstruyen la oscilación de izquierda a derecha. En el hueco se separan: la **caja negra** se queda plana porque nada la obliga a oscilar, mientras los puntos de colocación empujan a la **PINN** a continuar la oscilación a través del vacío.

Donde la PINN gana: el problema inverso


Los parámetros físicos como variables entrenables, junto con los pesos

Problema inverso: los parametros fisicos como variables entrenables



ω_0 recuperada con **0.8 % de error**

El período se lee de los cruces por cero: muchos ciclos lo restringen fuertemente.



β recuperada con **5.3 % de error**

El amortiguamiento se lee de la envolvente, mucho peor determinada con ruido y huecos. La misma jerarquía aparece en la sismología coronal real.

De P y τ a la física del lazo

Sismología coronal: medir lo que ningún instrumento resuelve

CAMPO MAGNÉTICO

$$c_k = 2L/P \quad \rightarrow \quad B = c_k \sqrt{(\mu_0(\rho_i + \rho_e)/2)}$$

Velocidad kink del modo transversal en un tubo delgado.

ESTRUCTURA FINA TRANSVERSAL

$$\tau/P = (2/\pi)(a/l)(\zeta+1)/(\zeta-1)$$

Absorción resonante en la capa inhomogénea del borde.

Diagnóstico	Valor verdadero	Estimado por la PINN	Error
Campo magnético B	7.86 G	7.79 G	0.8 %
Ancho relativo de la capa l/a	0.77	0.82	6.2 %

Partiendo de 14 medidas ruidosas de una posición, con un hueco de 8 minutos, y sin conocer ningún parámetro del sistema.

Honestidad computacional: PINN vs RK4

Las dos primeras filas son demoledoras para la PINN, y está bien que lo sean

	RK4	PINN
Tiempo de cómputo	21 ms	34 s
Error máximo en u [Mm]	7.7e-08	4.9e-03
¿Necesita conocer β y ω_0 ?	sí	no: los estima
¿Usa las observaciones?	no	sí
¿Tolera huecos y ruido?	no aplica	sí
¿Estima parámetros desconocidos?	no	sí
¿Reconstruye variables ocultas?	no	sí

Usa una PINN cuando el problema esté mal planteado en el sentido clásico. Si está bien planteado y solo hay que integrarlo, integra.

Desafíos y fronteras abiertas

No todo está resuelto

- › **Patología de gradientes.** Los términos de la pérdida pueden tener magnitudes de gradiente muy distintas y la convergencia se rompe. Adimensionalizar ayuda; hay esquemas de pesos adaptativos (Wang et al. 2021).
- › **Costo de la retropropagación.** Calcular derivadas de alto orden sobre mallas multidimensionales es intensivo en memoria de GPU. Cada orden de derivada agranda el grafo.
- › **Dinámica multiescala y rígida.** Los fenómenos astrofísicos varían enormemente en escala espacial y temporal. Las PINNs tienen modos de fallo caracterizados y reproducibles (Krishnapriyan et al. 2021): a veces la solución trivial gana.
- › **Y el riesgo silencioso.** La PINN acierta porque la ecuación impuesta era la correcta. Con física equivocada devuelve un ajuste bonito con parámetros sin sentido.

Qué llevarse de esta clase

- | | | |
|---|--|---|
| 1 | La física entra en la pérdida, no en el comentario | El residuo de la EDO evaluado sobre la propia red, con autograd. |
| 2 | Audita observables, no curvas | Energía, residuo, retrato de fase. Una curva que pasa por los puntos puede estar creando un 43 % de la energía inicial. |
| 3 | El nicho es el problema inverso | Para integrar una EDO conocida, integra. Para medir parámetros desde datos incompletos, la PINN es la herramienta. |
| 4 | Adam explora, L-BFGS remata | Sin la segunda fase, la mayoría de las PINNs de tutorial se quedan a medio converger. |

Referencias

PINNs

Raissi, Perdikaris & Karniadakis (2019), J. Comput. Phys. 378, 686 — el artículo fundacional.

Karniadakis et al. (2021), Nature Reviews Physics 3, 422 — panorama general.

Wang, Teng & Perdikaris (2021), SIAM J. Sci. Comput. — patologías de gradiente.

Krishnapriyan et al. (2021), NeurIPS — modos de fallo. Lectura obligatoria.

Sismología coronal

Nakariakov et al. (1999), Science 285, 862 — oscilaciones transversales con TRACE.

Nakariakov & Ofman (2001), A&A 372, L53 — campo magnético desde el período kink.

Ruderman & Roberts (2002), ApJ 577, 475; Goossens et al. (2002), A&A 394, L39 — absorción resonante.

Antolin & Van Doorsselaere (2019), Frontiers in Physics — estructura fina de lazos.

¿Preguntas?

Gracias por vuestra atención.

El cuaderno corre completo en ~3 minutos en CPU.